


# Clasificación de reportes de violencia

Modelos, aumentación de Severe y decisiones alrededor de un ancla

Marcel Herrera Rendón · Universidad de Sonora, México

## 01 Tres familias exploradas



Mismos 133 reportes, exactitud conjunta: TF-IDF+SGD 0.2331; Gemma+LoRA 0.1955; Qwen prompt 0.1053. Piloto LoRA: 625 ejemplos, 80 pasos. S2 completo, macro-F1: SVM caracteres 0.7642 / BETO 0.8198 (umbral 0.45). Protocolos distintos: no comparar paneles. [1]

## 02 Salidas adaptadas al problema


Severidad: una categoría ordenada  
Mild / Medium / High / Severe  
Focal ponderada y supervisión auxiliar en augrep08

Tipos: seis salidas que pueden coexistir  
Económica, física, patrimonial, psicológica, sexual, vicaria  
BETO final: seis sigmoid ≥ 0.45; N/A si ninguna se activa

Encoders: normalización de espacios, tokenización, truncamiento y padding por lote. Límites: S1 augrep08 512 tokens; S2 final 384. [1]

## 03 Aumentación dirigida a Severe

616 Severe / 13,630 reportes  
Solo entrenamiento. Se conservan los originales.




Indicios del original condicionan las plantillas.  
Semilla estable · Máximo 2 variantes por origen  
**+516 textos sintéticos con etiquetas heredadas.**

4.52% → 8.00% de Severe  
1,132 / 14,146 registros después de aumentar.

Balance parcial. Estas variantes usan plantillas, no un LLM. Pueden introducir hechos; la fidelidad de las etiquetas requiere auditoría. [2]

## Efecto en desarrollo


Cambio absoluto × 100 (puntos)  
Mismos 3,405 reportes · Cero = sin cambio



Base → aumentado: macro-F1 0.5481 → 0.5552;  
F1 Severe 0.4178 → 0.4335; recall 0.3961 → 0.3701.

**F1 mejora y recall baja.** Estilo, balance y pesos cambian juntos. Falta aislar sus efectos con controles y varias semillas. [2]

## 04 Recetas seleccionadas y un ancla para el ajuste final



S1 oficial: 0.60678 → 0.60798 macro-F1 (+0.00120). S2 permanece igual. Se ajustan decisiones alrededor de las recetas elegidas. [3]

### Desacuerdo entre anotadores

72.36% de 1,212 reportes de desarrollo tiene al menos un tipo con votos divididos. Tres votos, varianza interna  $p(1-p)$ . Sin identidades ni votos S1, no podemos comparar trabajadores. Análisis nuevo, posterior al paper. Hay 24 discrepancias hard/soft sin explicación conocida. [4]

### Sistema completo · Test oficial

**Severidad: 0.60798 macro-F1 · 3.º / 16**  
**Tipos: 0.87016 micro-F1 · 6.º / 15**  
El test orientó la selección. Generalización entre instituciones aún pendiente. [1]

[1] Herrera Rendón (2026). WomenHelp: métodos y resultados. docs/method.md; docs/results.md.  
[2] Aumentación: src/womenhelp\_competition/text\_augmentation.py; results/evidence.json.  
[3] Router de severidad: scripts/materialize\_hailmary\_s1\_foldbag\_router\_20260507.py.  
[4] Análisis nuevo de anotación: docs/annotation\_consensus.md; scripts/analyze\_annotations.py.  
[github.com/mariron42/clasificador\\_violencia](https://github.com/mariron42/clasificador_violencia)

