


Clasificación de reportes de violencia

Modelos, aumentación de Severe y decisiones alrededor de un ancla

Marcel Herrera Rendón · Universidad de Sonora, México

01 Tres familias exploradas



Mismos 133 reportes, exactitud conjunta: TF-IDF+SGD 0.2331; Gemma+LoRA 0.1955; Qwen prompt 0.1053. Piloto LoRA: 625 ejemplos, 80 pasos. S2 completo, macro-F1: SVM caracteres 0.7642 / BETO 0.8198 (umbral 0.45). Protocolos distintos: no comparar paneles. [1, 2]

02 Salidas adaptadas al problema


Severidad: una categoría ordenada
Mild / Medium / High / Severe
Focal ponderada y supervisión auxiliar en augrep08

Tipos: seis salidas que pueden coexistir
Económica, física, patrimonial, psicológica, sexual, vicaria
BETO final: seis sigmoid ≥ 0.45 ; N/A si ninguna se activa

Encoders: normalización de espacios, tokenización, truncamiento y padding por lote. Límites: S1 augrep08 512 tokens; S2 final 384.

03 Aumentación dirigida a Severe

616 Severe / 13,630 reportes
Solo entrenamiento. Se conservan los originales.




Indicios del original condicionan las plantillas.
Semilla estable · Máximo 2 variantes por origen
+516 textos sintéticos con etiquetas heredadas.

4.52% → 8.00% de Severe
1,132 / 14,146 registros después de aumentar.

Balance parcial. Estas variantes usan plantillas, no un LLM. Pueden introducir hechos; la fidelidad de las etiquetas requiere auditoría. [2]

Efecto en desarrollo


Cambio absoluto × 100 (puntos)
Mismos 3,405 reportes · Cero = sin cambio



Base → aumentado: macro-F1 0.5481 → 0.5552;
F1 Severe 0.4178 → 0.4335; recall 0.3961 → 0.3701.

F1 mejora y recall baja. Estilo, balance y pesos cambian juntos. Falta aislar sus efectos con controles y varias semillas. [2]

04 Recetas seleccionadas y un ancla para el ajuste final



S1 oficial: 0.60678 → 0.60798 macro-F1 (+0.00120). S2 permanece igual. Se ajustan decisiones alrededor de las recetas elegidas. [1]

Desacuerdo entre anotadores

72.36% de 1,212 reportes de desarrollo tiene al menos un tipo con votos divididos. Tres votos, varianza interna $p(1-p)$. Sin identidades ni votos S1, no podemos comparar trabajadores. Análisis nuevo, posterior al paper. [3]

Sistema completo · Test oficial

Severidad: 0.60798 macro-F1 · 3.º / 16
Tipos: 0.87016 micro-F1 · 6.º / 15
El test orientó la selección. Generalización entre instituciones aún pendiente. [1]

[1] Herrera Rendón, marcelhr at WomenHelp 2026: Conservative Ensembles and Ordinal Routing for Gender-Based Violence Classification. Paper corregido, 2026. [2] Proyecto: reporte comparativo balanced133, text_augmentation.py y augrep08_metrics_summary.json. [3] Starting kit, develSoft.csv. Cálculo reproducible del 20-09-2026; 877/1,212 con voto dividido en L0–L5. Hay 24 discrepancias hard/soft en desarrollo, de causa no determinada. Véase docs/annotation_consensus.md.